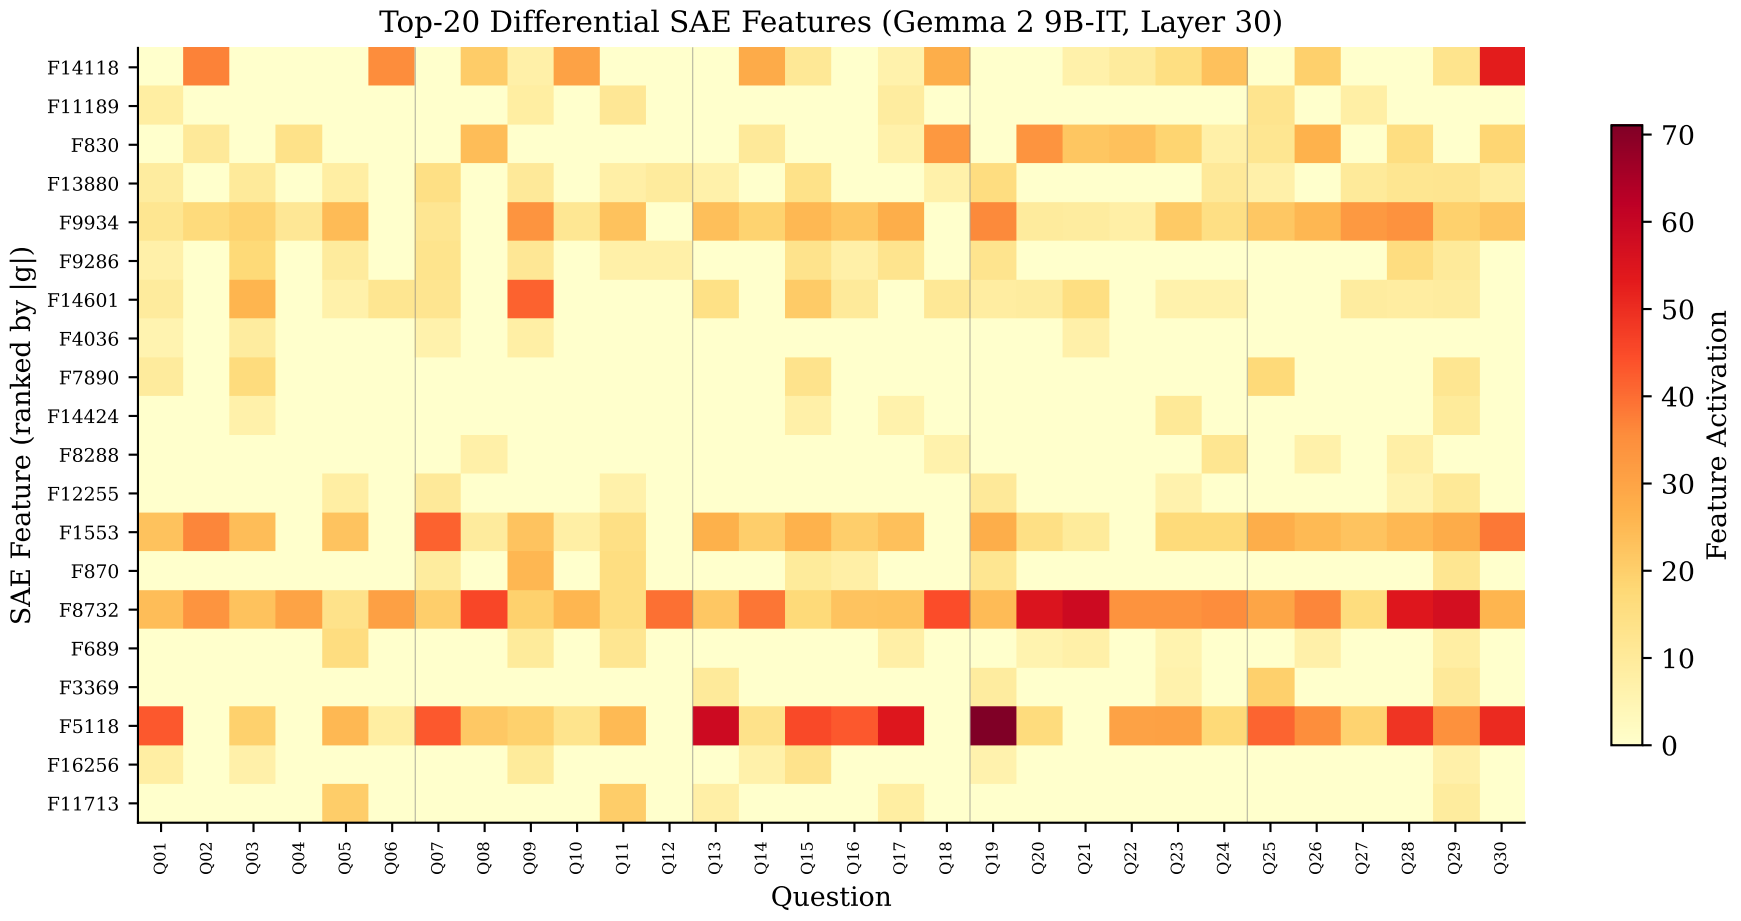
Top-20 Differential SAE Features (Gemma 2 9B-IT, Layer 30)
SAE Feature (ranked by |g|)
F14118
F11189
F830
F13880
F9934
F9286
F14601
F4036
F7890
F14424
F8288
F12255
F1553
F870
F8732
F689
F3369
F5118
F16256
F11713
Q01
Q02
Q03
Q04
Q05
Q06
Q07
Q08
Q09
Q10
Q11
Q12
Q13
Q14
Q15
Q16
Q17
Q18
Q19
Q20
Q21
Q22
Q23
Q24
Q25
Q26
Q27
Q28
Q29
Q30
Question
Feature Activation
0
10
20
30
40
50
60
70